rapport

April 3, 2026

1 Rapport synthétique métier sur le rendement agricole

1.1 Résumé exécutif

Ce notebook présente l'analyse exploratoire des données, les variables les plus influentes et les choix retenus pour la suite du projet. La construction opérationnelle du dataset consolidé est réalisée dans `preparation.ipynb`, tandis que la modélisation est traitée dans `modelisation.ipynb`.

Principaux résultats :

- le dataset `crop_yield.csv` est très lisible et très propre, mais il semble aussi très artificiel ou déjà fortement nettoyé ;
- dans ce dataset, la pluie est le facteur le plus structurant du rendement, devant la température ;
- l'irrigation et la fertilisation ont un effet net, alors que les écarts entre cultures restent plus faibles ;
- aucune variable de surface en hectares n'est disponible ;
- quelques valeurs atypiques devront être traitées avant la modélisation ;
- le second jeu de données sert surtout à documenter les choix de structuration et d'enrichissement de la future base d'entraînement.

1.2 Comment lire le dataset `crop_yield.csv`

Le dataset `crop_yield.csv` est un jeu de données simple, très propre et facile à lire. Il fonctionne bien pour une première analyse exploratoire, car il permet de visualiser rapidement les relations entre pluie, température, pratiques culturales et rendement.

Ce que ce dataset permet de bien faire :

- comprendre les ordres de grandeur du rendement ;
- visualiser les effets apparents de la pluie, de la température, de l'irrigation et du fertilisant ;
- produire un rapport métier lisible avec des graphiques et des tableaux faciles à interpréter.

Ce qu'il ne permet pas de faire directement :

- mesurer l'effet de la taille des parcelles, car aucune surface en hectares n'est fournie ;
- conclure de façon certaine sur des recommandations terrain universelles ;
- ignorer les quelques valeurs atypiques repérées dans la cible.

```
Dimensions du dataset : 1,000,000 lignes x 10 colonnes
Taille de l'échantillon pour les graphiques lourds : 50,000 lignes
```

1.3 Lecture du dataset `crop_yield.csv`

Cette première partie se concentre sur `crop_yield.csv`. Avant d'interpréter les rendements, il faut vérifier que cette base est lisible, complète et cohérente. Les éléments ci-dessous présentent sa taille, ses variables et ses ordres de grandeur principaux.

```
data.info() :
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1000000 entries, 0 to 999999
Data columns (total 10 columns):
 #   Column                  Non-Null Count    Dtype
---  ------                  --------------    -----
 0   Region                  1000000 non-null  object
 1   Soil_Type               1000000 non-null  object
 2   Crop                    1000000 non-null  object
 3   Rainfall_mm             1000000 non-null  float64
 4   Temperature_Celsius     1000000 non-null  float64
 5   Fertilizer_Used         1000000 non-null  bool
 6   Irrigation_Used         1000000 non-null  bool
```

```
 7   Weather_Condition       1000000 non-null  object
 8   Days_to_Harvest         1000000 non-null  int64
 9   Yield_tons_per_hectare  1000000 non-null  float64
dtypes: bool(2), float64(3), int64(1), object(4)
memory usage: 62.9+ MB
```

data.describe() :

	mean	std	min	25%	50%	75%	max
Rainfall_mm	549.98	259.85	100.00	324.89	550.12	774.74	1,000.00
Temperature_Celsius	27.50	7.22	15.00	21.25	27.51	33.75	40.00
Days_to_Harvest	104.50	25.95	60.00	82.00	104.00	127.00	149.00
Yield_tons_per_hectare	4.65	1.70	-1.15	3.42	4.65	5.88	9.96

data[categorical_summary_columns].describe() :

	count	unique	top	freq
Region	1000000	4	North	250173
Soil_Type	1000000	6	Sandy	167119
Crop	1000000	6	Maize	166824
Fertilizer_Used	1000000	2	False	500060
Irrigation_Used	1000000	2	False	500509
Weather_Condition	1000000	3	Sunny	333790

1.3.1 Données manquantes, doublons et cohérence générale

Cette vérification répond à une question simple pour un lecteur métier : peut-on faire confiance au jeu de données avant de l'utiliser pour expliquer les rendements ou entraîner un modèle ?

```
Nombre total de valeurs manquantes : 0
Nombre de lignes dupliquées complètes : 0
```

	nb_nan	pct_nan
Region	0	0.00
Soil_Type	0	0.00
Crop	0	0.00
Rainfall_mm	0	0.00
Temperature_Celsius	0	0.00
Fertilizer_Used	0	0.00
Irrigation_Used	0	0.00
Weather_Condition	0	0.00
Days_to_Harvest	0	0.00
Yield_tons_per_hectare	0	0.00

	nb_modalites
Soil_Type	6
Crop	6
Region	4
Weather_Condition	3

```
Fertilizer_Used              2
Irrigation_Used              2
```

1.3.2 Valeurs atypiques

Les valeurs extrêmes ne remettent pas forcément le dataset en cause, mais elles peuvent fausser les moyennes et perturber la modélisation. Le tableau suivant aide à repérer les anomalies à discuter.

```
Nombre de rendements négatifs : 231

                        borne_basse  borne_haute  nb_outliers  pct_outliers
Yield_tons_per_hectare        -0.27         9.57           84          0.01
Rainfall_mm                 -349.88     1,449.51            0          0.00
Temperature_Celsius            2.51        52.50            0          0.00
Days_to_Harvest               14.50       194.50            0          0.00

Yield_tons_per_hectare négatifs (10 premiers) :

        Rainfall_mm  Temperature_Celsius  Days_to_Harvest  \
773387       174.91                16.58              128
889758       107.62                19.00              127
77504        120.42                22.81              120
737655       142.76                21.88              102
387230       120.57                20.12              144
770740       133.18                24.93               72
682138       112.40                17.17              142
243824       120.73                38.34               97
363782       102.04                20.43              123
572365       115.34                30.60               86

        Yield_tons_per_hectare
773387                   -1.15
889758                   -0.88
77504                    -0.84
737655                   -0.82
387230                   -0.80
770740                   -0.73
682138                   -0.70
243824                   -0.67
363782                   -0.65
572365                   -0.60
```

1.4 Répartition générale des variables

Les graphiques suivants montrent comment se répartissent la pluie, la température, le temps jusqu'à la récolte et le rendement. Ils donnent une première idée de la variabilité du contexte agronomique observé.

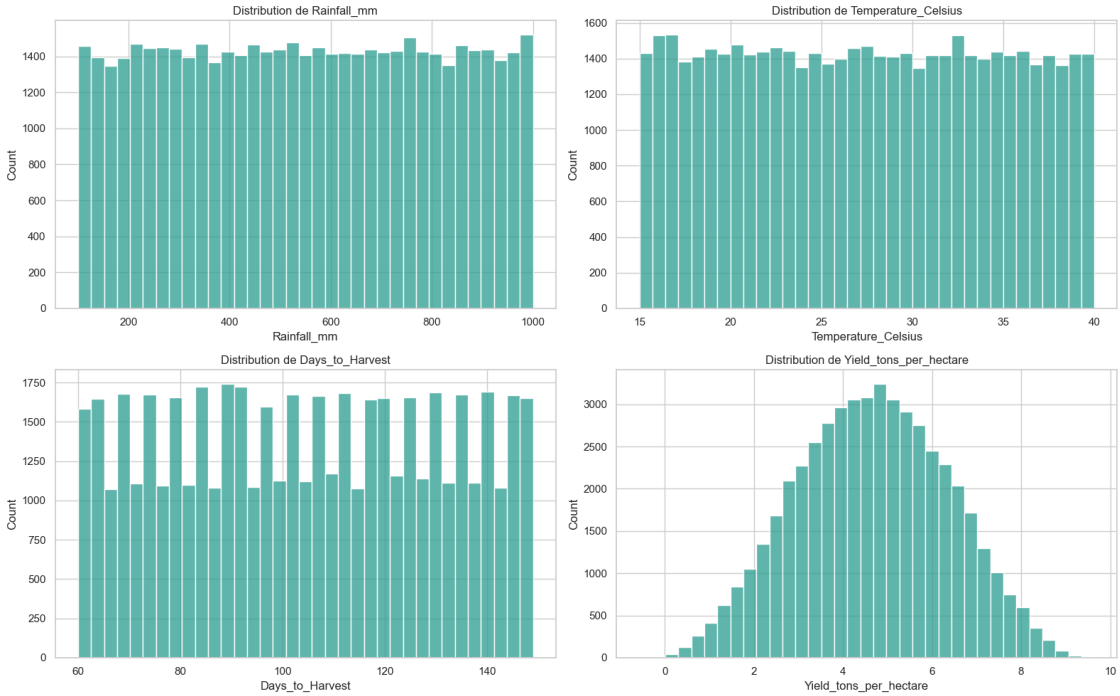
Distribution de Rainfall_mm
Count
Rainfall_mm
Distribution de Temperature_Celsius
Count
Temperature_Celsius
Distribution de Days_to_Harvest
Count
Days_to_Harvest
Distribution de Yield_tons_per_hectare
Count
Yield_tons_per_hectare

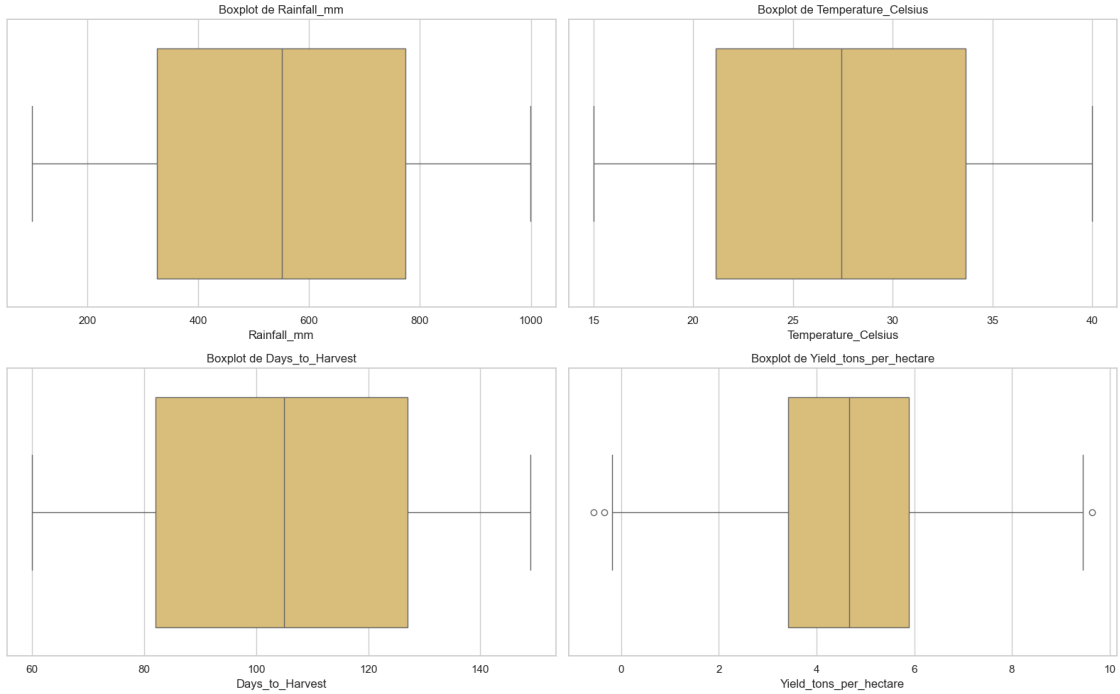
Boxplot de Rainfall_mm
Rainfall_mm
Boxplot de Temperature_Celsius
Temperature_Celsius
Boxplot de Days_to_Harvest
Days_to_Harvest
Boxplot de Yield_tons_per_hectare
Yield_tons_per_hectare

1.5 Comparaison des catégories

Cette section compare les grandes catégories du dataset : cultures, régions, types de sol et météo observée. Pour un public métier, elle permet surtout de voir si certaines catégories se détachent clairement.

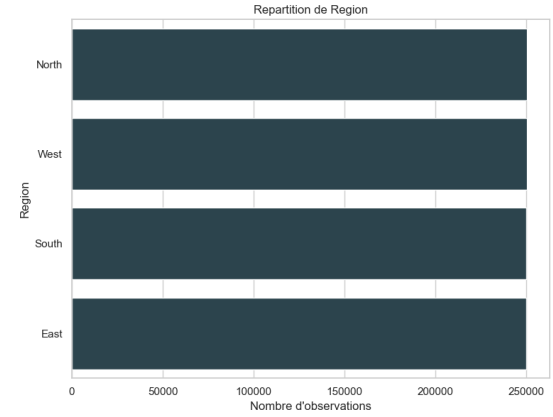

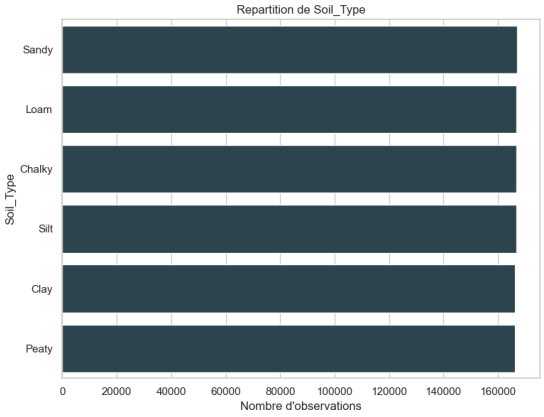

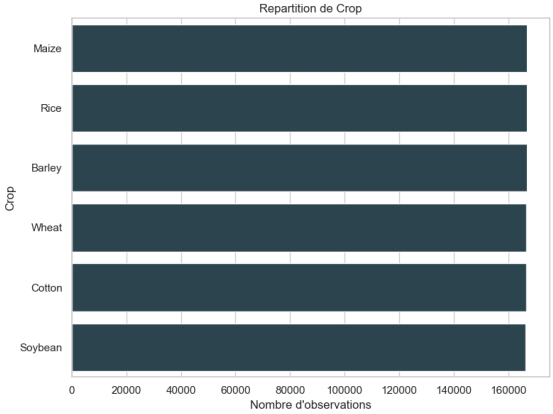

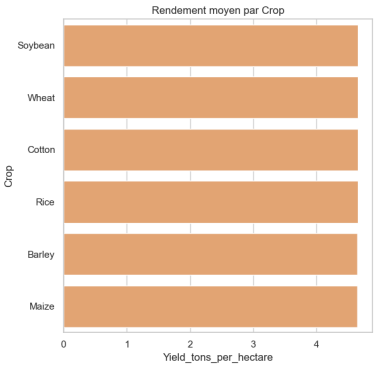

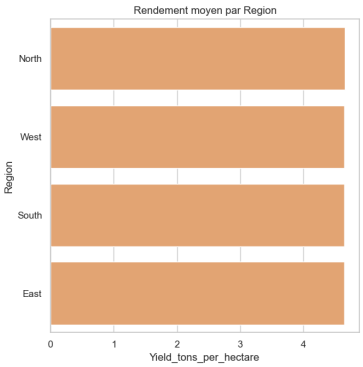

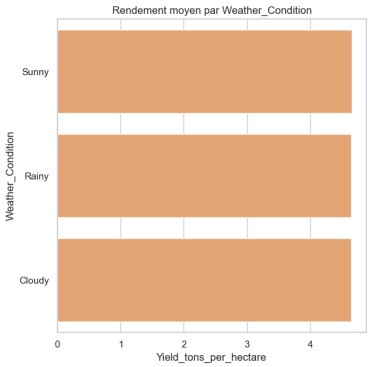

1.6 Variables qui influencent le rendement

La matrice de corrélation et les nuages de points servent ici à repérer les facteurs les plus liés au rendement. Il ne s'agit pas encore d'un modèle prédictif, mais d'une lecture visuelle des relations les plus plausibles.

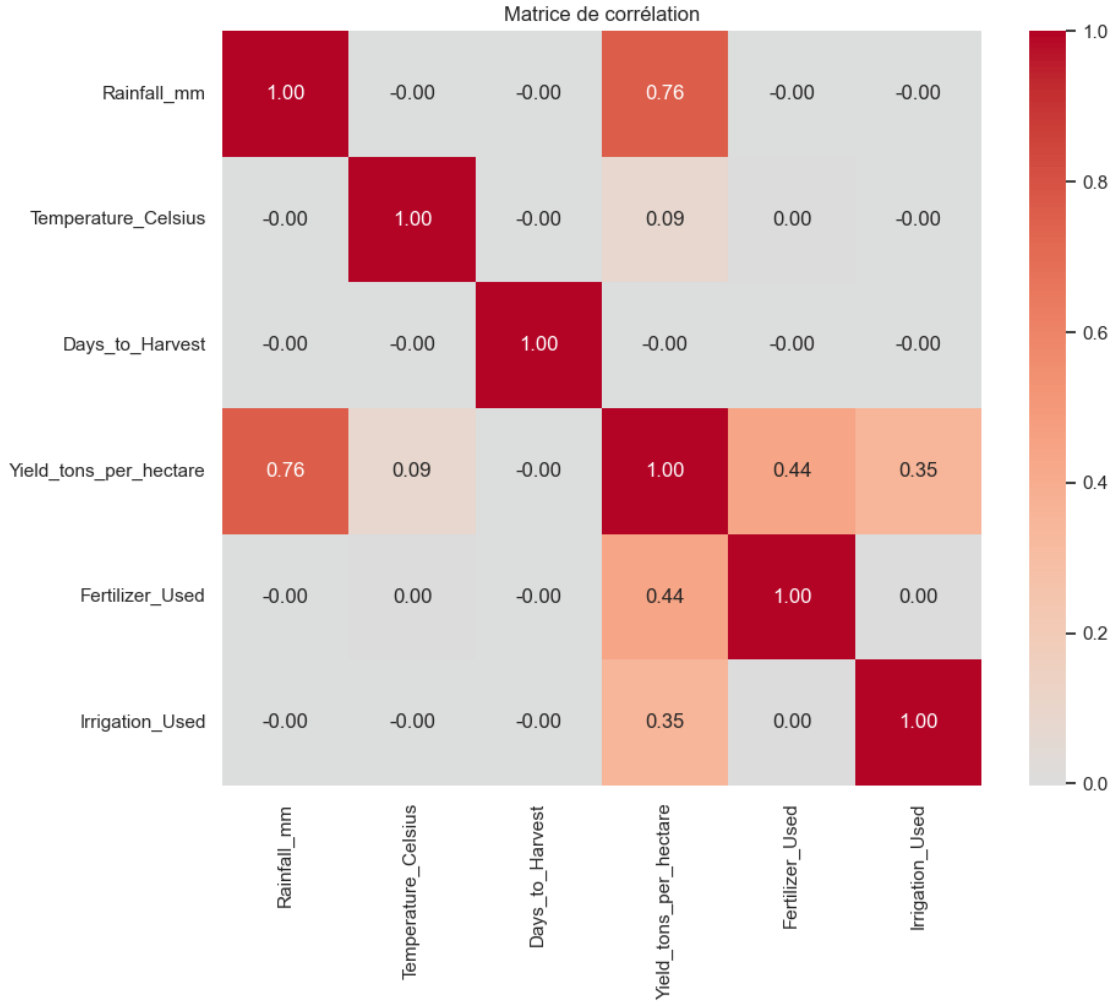

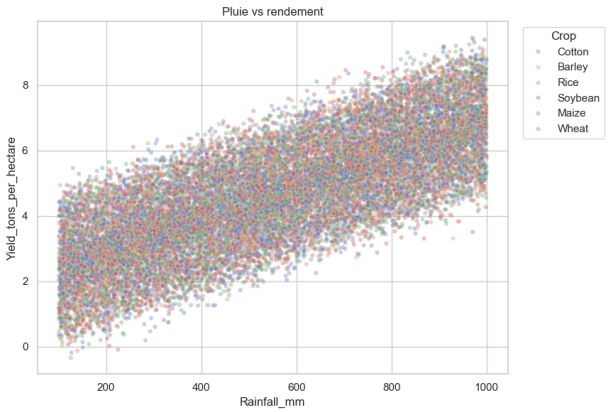

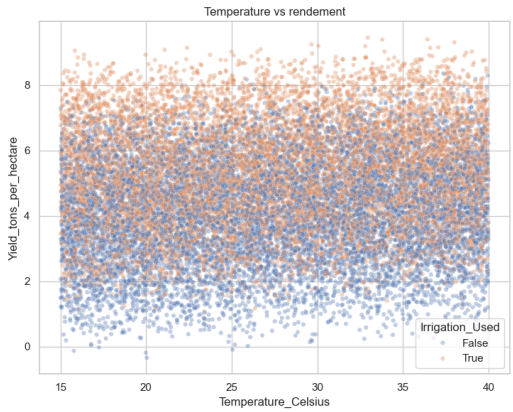

1.7 Synthèse intermédiaire

À ce stade, les principaux constats à retenir sur `crop_yield.csv` sont les suivants :

- le dataset est propre sur les NaN et les doublons complets,
- les categories sont tres equilibrees, ce qui suggere un jeu de données probablement synthétique ou déjà très travaillé,
- quelques rendements négatifs ou extrêmes existent et devront etre arbitres avant la modélisation,
- les visualisations donnent une première lecture des liens potentiels avec le rendement.

1.8 Lecture métier détaillée

Pour aller au-delà des graphiques, on ajoute des tableaux de synthèse qui permettent de commenter précisément les rendements moyens observés dans `crop_yield.csv`.

Point important : ce dataset ne contient pas une variable de surface en hectares. La mesure disponible est `Yield_tons_per_hectare`, donc un rendement déjà normalisé par hectare. On peut comparer l'effet de la pluie et de la température sur le rendement par hectare, mais pas mesurer l'effet de la taille des parcelles.

```
                    yield_moyen_t_ha  yield_median_t_ha  yield_min_t_ha  \
ensemble_du_dataset              4.65               4.65           -1.15

                    yield_max_t_ha
ensemble_du_dataset            9.96
```

```
         yield_moyen_t_ha  yield_median_t_ha
Crop
Soybean              4.65               4.66
Wheat                4.65               4.66
Cotton               4.65               4.65
Rice                 4.65               4.65
Barley               4.65               4.65
Maize                4.64               4.64
```

```
                nb_lignes  yield_moyen_t_ha  yield_median_t_ha
Rainfall_level
Faible             250000              2.96               2.96
Moyenne-           250000              4.09               4.09
Moyenne+           250000              5.21               5.21
Forte              250000              6.33               6.33
```

```
                   nb_lignes  yield_moyen_t_ha  yield_median_t_ha
Temperature_level
Fraiche               250000              4.46               4.45
Temperee-             250000              4.59               4.59
```

```
Temperee+             250000              4.71               4.71
Chaude                250000              4.84               4.84

               nb_lignes  yield_moyen_t_ha  yield_median_t_ha
Harvest_level
Courte            255094              4.66               4.66
Moyenne-          244929              4.65               4.65
Moyenne+          256220              4.64               4.64
Longue            243757              4.65               4.66

                 nb_lignes  yield_moyen_t_ha
Fertilizer_Used
False               500060              3.90
True                499940              5.40

                 nb_lignes  yield_moyen_t_ha
Irrigation_Used
False               500509              4.05
True                499491              5.25

                                nb_lignes  yield_moyen_t_ha
Fertilizer_Used Irrigation_Used
False           False              250662              3.30
                True               249398              4.50
True            False              249847              4.80
                True               250093              6.00

Temperature_level  Fraiche  Temperee-  Temperee+  Chaude
Rainfall_level
Faible                2.77       2.90       3.03    3.15
Moyenne-              3.90       4.02       4.15    4.28
Moyenne+              5.02       5.15       5.28    5.41
Forte                 6.15       6.28       6.38    6.52
```

1.8.1 Explication des variables clés

Les tableaux ci-dessous décrivent `crop_yield.csv` et permettent de résumer les grandes relations visibles entre les variables agronomiques et le rendement.

Le rendement moyen global y est de **4,649 t/ha**, avec une médiane de **4,652 t/ha**. La distribution est donc assez centrée, même si quelques valeurs négatives et extrêmes existent.

L'effet le plus net vient de la pluie. Le quartile le plus sec, situé approximativement entre **100 et 325 mm**, atteint **2,963 t/ha** en moyenne. Le quartile le plus humide, entre **775 et 1 000 mm**, monte à **6,333 t/ha**. L'écart est donc d'environ **3,37 t/ha**, ce qui fait de la pluie la variable la plus structurante du dataset.

La température joue aussi dans le bon sens, mais plus modérément. On passe de **4,460 t/ha** dans le quartile le plus frais, autour de **15 à 21,3 °C**, à **4,840 t/ha** dans le quartile le plus chaud, autour de **33,8 à 40 °C**. L'effet existe, mais il reste beaucoup plus faible que celui de la pluie.

Le tableau croisé pluie x température montre bien cette hiérarchie. La situation la moins favorable

est **faible pluie + température fraîche** avec **2,771 t/ha**, alors que la combinaison la plus favorable est **forte pluie + température chaude** avec **6,518 t/ha**. En pratique, la pluie domine la température dans l'explication des rendements.

Concernant les hectares, il faut être précis : **aucune variable de surface n'est présente** dans ce fichier. On ne peut donc pas comparer les rendements selon la taille des parcelles. La seule mesure disponible est déjà normalisée par hectare avec `Yield_tons_per_hectare`. Si l'on cherche une variable proche pour enrichir la lecture, `Days_to_Harvest` varie très peu selon les quartiles, avec des rendements moyens compris entre **4,640 et 4,657 t/ha**, ce qui suggère un effet faible.

Enfin, les écarts entre cultures restent faibles : de **4,641 t/ha** pour le maïs à **4,654 t/ha** pour le soja. En revanche, les pratiques agricoles marquent davantage le rendement moyen : **3,900 t/ha** sans fertilisant contre **5,400 t/ha** avec fertilisant, et **4,050 t/ha** sans irrigation contre **5,250 t/ha** avec irrigation. Le tableau croisé confirme cette logique : le rendement moyen le plus faible est observé sans fertilisant et sans irrigation (**3,300 t/ha**), et le plus élevé quand les deux sont activés (**6,000 t/ha**). Cela renforce l'idée d'un dataset très structuré, probablement synthétique, où certaines relations sont volontairement nettes.

1.9 Lecture du jeu de données agronomiques et climatiques

1.10 Vue d'ensemble des fichiers du dossier `Crop Yield Prediction Dataset`

Cette partie complète le rapport métier en décrivant le second jeu de données disponible dans la mission. L'objectif n'est pas d'implémenter ici la fusion, mais d'expliquer quelles sources sont fiables, quelles limites elles présentent et quels choix cela implique pour la suite du projet. La construction effective de la base consolidée est réservée à `preparation.ipynb`.

Les fichiers étudiés sont : `yield.csv`, `yield_df.csv`, `rainfall.csv`, `pesticides.csv` et `temp.csv`.

```
          fichier  nb_lignes  nb_colonnes  nan_total  colonnes_avec_nan  \
0  pesticides.csv       4349            7          0                  0
1    rainfall.csv       6727            3        774                  1
2        temp.csv      71311            3       2547                  1
3       yield.csv      56717           12          0                  0
4    yield_df.csv      28242            8          0                  0

   nb_colonnes_numeriques  nb_colonnes_non_numeriques
0                       2                           5
1                       1                           2
2                       2                           1
3                       6                           6
4                       6                           2
```

1.11 Visualisations de synthèse des fichiers

Avant d'entrer dans le détail, ces graphiques comparent le volume des fichiers, la quantité de valeurs manquantes et la structure des colonnes. Pour un lecteur métier, ils servent surtout à repérer quelles sources sont les plus solides et lesquelles demanderont plus de précautions avant d'alimenter un modèle.

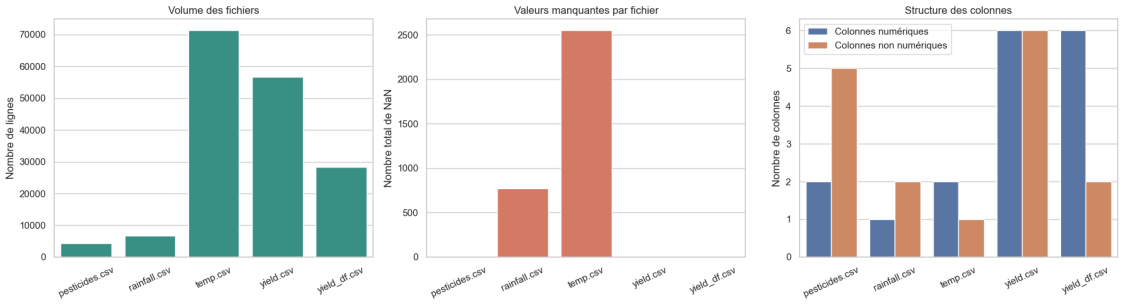

1.12 Couverture temporelle des fichiers

Les fichiers ne couvrent pas exactement les mêmes périodes ni les mêmes volumes d'observations par année. Cette lecture temporelle permet d'anticiper les années réellement communes entre les sources et d'évaluer la profondeur historique mobilisable pour construire la base d'entraînement.

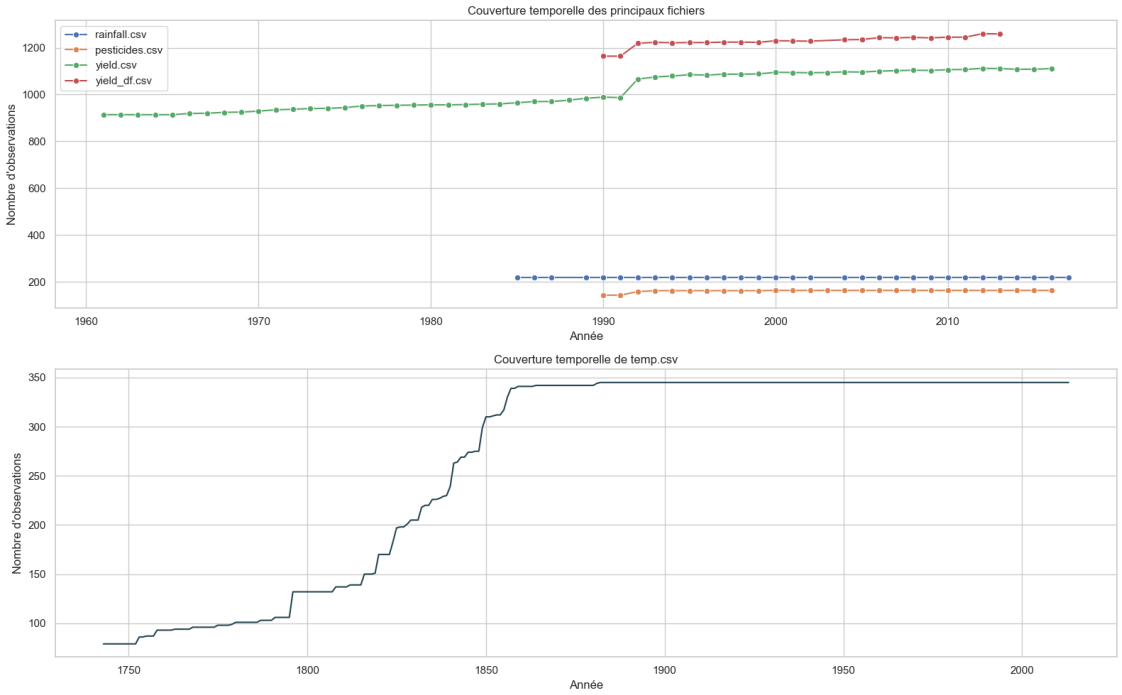

1.13 Colonnes, types de données et valeurs manquantes par fichier

Les tableaux ci-dessous détaillent, pour chaque CSV, les noms de colonnes, les types détectés, le nombre de valeurs manquantes et le nombre de modalités distinctes. Cette lecture répond à une question simple : quelles sources sont directement exploitables, et lesquelles demandent un travail de préparation avant d'être intégrées au pipeline ?

```
===== pesticides.csv =====

   colonne    dtype  nb_nan  pct_nan  nb_modalites
0   Domain   object       0     0.00             1
1     Area   object       0     0.00           168
2  Element   object       0     0.00             1
3     Item   object       0     0.00             1
4     Year    int64       0     0.00            27
5     Unit   object       0     0.00             1
6    Value  float64       0     0.00          2825

           Domain     Area Element                Item  Year  \
0  Pesticides Use  Albania     Use  Pesticides (total)  1990
1  Pesticides Use  Albania     Use  Pesticides (total)  1991
2  Pesticides Use  Albania     Use  Pesticides (total)  1992

                           Unit  Value
0  tonnes of active ingredients 121.00
1  tonnes of active ingredients 121.00
2  tonnes of active ingredients 121.00


===== rainfall.csv =====

                        colonne   dtype  nb_nan  pct_nan  nb_modalites
0                          Area  object       0     0.00           217
1                          Year   int64       0     0.00            31
2  average_rain_fall_mm_per_year  object     774    11.51           174

          Area  Year average_rain_fall_mm_per_year
0  Afghanistan  1985                           327
1  Afghanistan  1986                           327
2  Afghanistan  1987                           327


===== temp.csv =====

    colonne    dtype  nb_nan  pct_nan  nb_modalites
0      year    int64       0     0.00           271
1   country   object       0     0.00           137
2  avg_temp  float64    2547     3.57          3304

   year        country  avg_temp
0  1849  Côte D'Ivoire     25.58
1  1850  Côte D'Ivoire     25.52
2  1851  Côte D'Ivoire     25.67


===== yield.csv =====

         colonne   dtype  nb_nan  pct_nan  nb_modalites
0    Domain Code  object       0     0.00             1
```

```
1         Domain  object       0     0.00             1
2      Area Code   int64       0     0.00           212
3           Area  object       0     0.00           212
4   Element Code   int64       0     0.00             1
5        Element  object       0     0.00             1
6      Item Code   int64       0     0.00            10
7           Item  object       0     0.00            10
8      Year Code   int64       0     0.00            56
9           Year   int64       0     0.00            56
10          Unit  object       0     0.00             1
11         Value   int64       0     0.00         36815

  Domain Code Domain  Area Code         Area  Element Code Element  Item Code  \
0          QC  Crops          2  Afghanistan          5419   Yield         56
1          QC  Crops          2  Afghanistan          5419   Yield         56
2          QC  Crops          2  Afghanistan          5419   Yield         56

    Item  Year Code  Year   Unit  Value
0  Maize       1961  1961  hg/ha  14000
1  Maize       1962  1962  hg/ha  14000
2  Maize       1963  1963  hg/ha  14260


===== yield_df.csv =====

                        colonne    dtype  nb_nan  pct_nan  nb_modalites
0                     Unnamed: 0    int64       0     0.00         28242
1                           Area   object       0     0.00           101
2                           Item   object       0     0.00            10
3                           Year    int64       0     0.00            23
4                    hg/ha_yield    int64       0     0.00         11514
5  average_rain_fall_mm_per_year  float64       0     0.00           100
6              pesticides_tonnes  float64       0     0.00          1673
7                       avg_temp  float64       0     0.00          1831

   Unnamed: 0     Area         Item  Year  hg/ha_yield  \
0           0  Albania        Maize  1990        36613
1           1  Albania     Potatoes  1990        66667
2           2  Albania  Rice, paddy  1990        23333

   average_rain_fall_mm_per_year  pesticides_tonnes  avg_temp
0                       1,485.00             121.00     16.37
1                       1,485.00             121.00     16.37
2                       1,485.00             121.00     16.37
```

1.13.1 Premiers constats sur les fichiers

- `yield.csv` est la source brute la plus riche pour le rendement : on y trouve la zone (`Area`), la culture (`Item`), l'année (`Year`) et la valeur de rendement (`Value`) sans valeur manquante.
- `rainfall.csv` est un petit fichier très utile pour la pluie annuelle, mais il contient une colonne

`Area` avec un espace initial et la variable `average_rain_fall_mm_per_year` est lue en texte, avec des valeurs manquantes codées sous la forme `...`

- `pesticides.csv` est propre sur les valeurs manquantes et propose un indicateur d'usage de pesticides par zone et par année.
- `temp.csv` contient la température moyenne (`avg_temp`), mais avec des valeurs manquantes et surtout de très nombreux doublons sur `country + year`, ce qui impose une agrégation ou une règle de dédoublonnage avant toute jointure.
- `yield_df.csv` ressemble à un fichier déjà enrichi, sans valeurs manquantes, mais il ne doit pas être pris comme vérité finale : sa granularité n'est pas proprement unique sur `Area + Item + Year`.

1.14 Focus visuel sur `yield.csv`

`yield.csv` est la source brute la plus structurante pour un futur travail de fusion, car elle porte la cible de rendement par zone, culture et année. Les graphiques suivants permettent d'en lire la répartition dans le temps, par culture et par intensité de rendement.

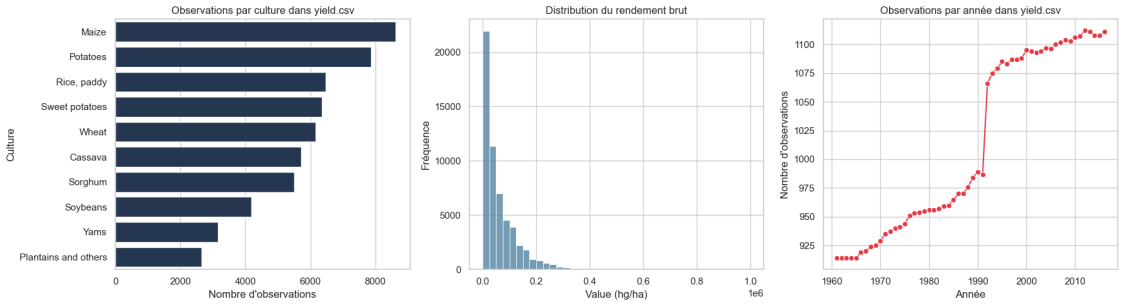

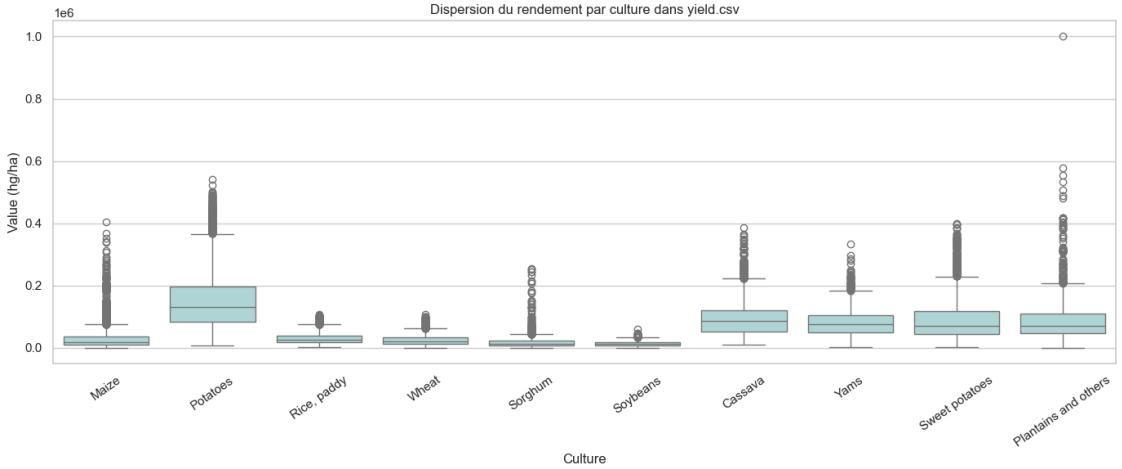

1.15 Focus visuel sur `rainfall.csv` et `pesticides.csv`

Ces deux fichiers portent deux familles de variables explicatives futures : l'eau disponible à grande échelle et l'intensité d'usage des pesticides. Les visualisations servent ici à qualifier la qualité des données, l'ampleur des manquants et les grands ordres de grandeur observés.

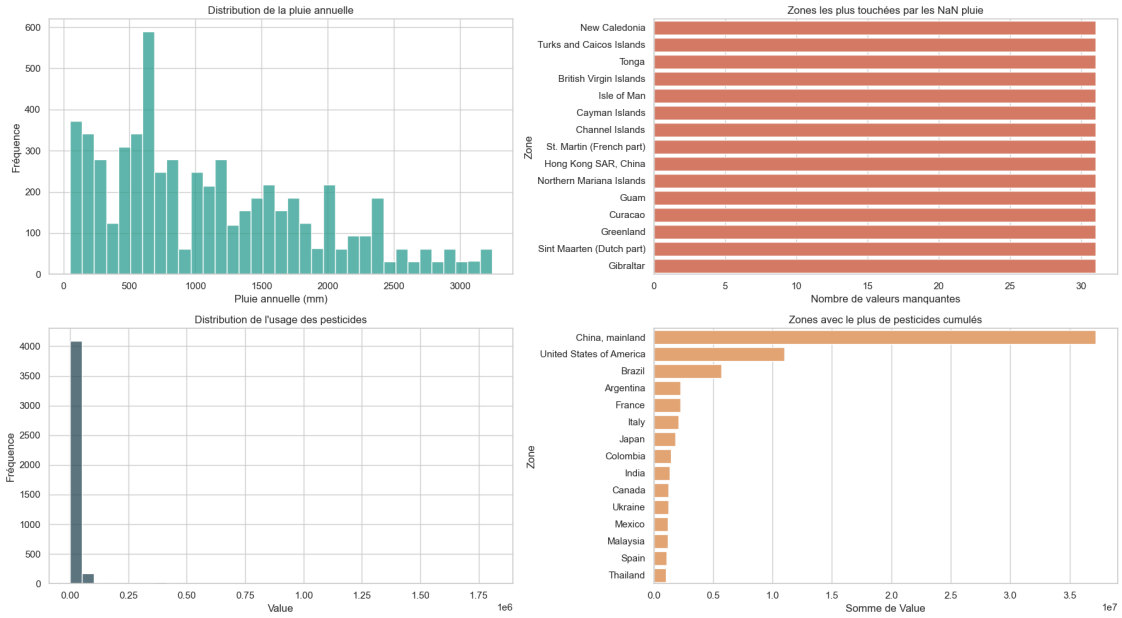

1.16 Focus visuel sur `temp.csv` et `yield_df.csv`

`temp.csv` apporte le contexte thermique, mais sa qualité doit être contrôlée à cause des doublons. `yield_df.csv` ressemble à une table déjà enrichie ; on l'explore ici pour comprendre sa structure, ses distributions et les risques qu'elle présente avant toute utilisation plus poussée.

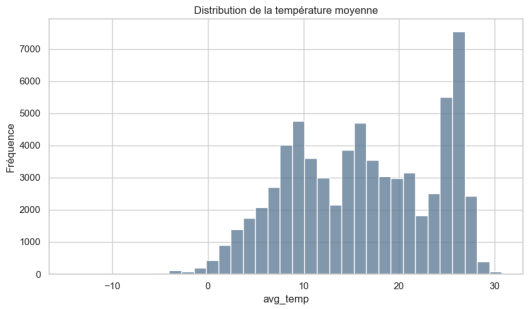

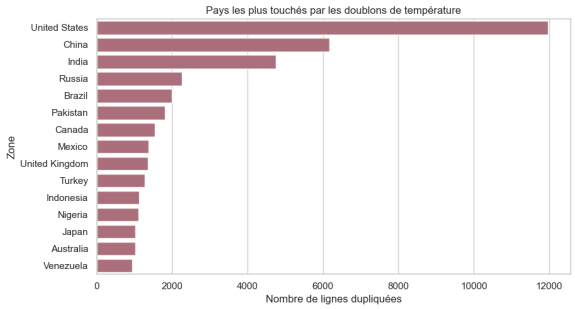

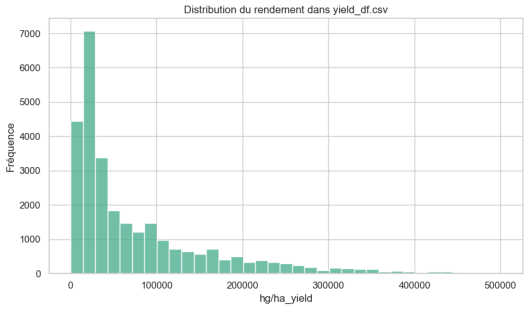

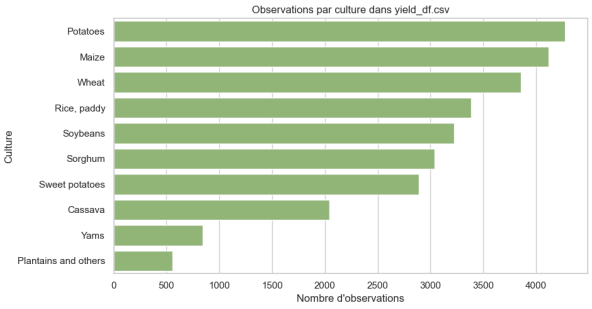

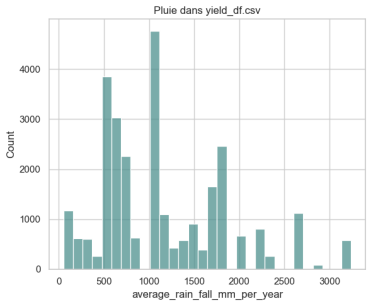

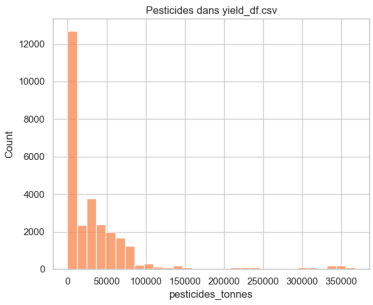

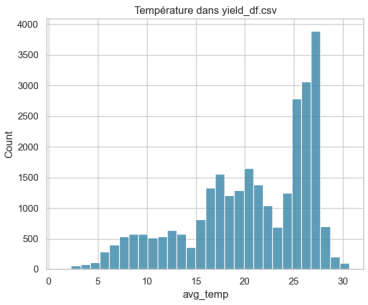

1.17 Choix retenus pour structurer les données

Avant toute fusion, il faut identifier la granularité de chaque fichier et vérifier quelles clés de jointure semblent plausibles. Ici, le but est de documenter le raisonnement métier et technique qui guidera ensuite la construction du dataset dans `preparation.ipynb`.

```
         fichier granularite_observee              cle_potentielle  \
0    rainfall.csv          Area + Year                  Area + Year
1  pesticides.csv          Area + Year                  Area + Year
2        temp.csv        country + year  Area + Year après renommage
3       yield.csv   Area + Item + Year           Area + Item + Year
4    yield_df.csv   Area + Item + Year           Area + Item + Year

   doublons_sur_cle                                       commentaire
0                 0  clé exploitable après renommage de ` Area` et …
1                 0                       clé exploitable telle quelle
```

```
2            42797  clé non exploitable en l'état à cause des doub…
3                0  bonne table de base pour un futur dataset fusi…
4            15112  fichier enrichi utile pour audit, mais non uni…

                                     comparaison  cles_communes  \
0         yield.csv vs rainfall.csv sur Area + Year           4847
1       yield.csv vs pesticides.csv sur Area + Year           4318
2             yield.csv vs temp.csv sur Area + Year           5580
3      yield_df.csv vs rainfall.csv sur Area + Year           2250
4    yield_df.csv vs pesticides.csv sur Area + Year           2250
5          yield_df.csv vs temp.csv sur Area + Year           2250
6  yield_df.csv vs yield.csv sur Area + Item + Year          13130

   cles_de_reference  taux_couverture_pct
0              10572                45.85
1              10572                40.84
2              10572                52.78
3               2250               100.00
4               2250               100.00
5               2250               100.00
6              13130               100.00

        besoin_metier                 variable_proxy  \
0           Irrigation  average_rain_fall_mm_per_year
1        Fertilisation      Value / pesticides_tonnes
2  Contexte climatique                       avg_temp

                      fichiers  \
0    rainfall.csv, yield_df.csv
1  pesticides.csv, yield_df.csv
2        temp.csv, yield_df.csv

                                    lecture_metier
0  proxy indirect de disponibilité en eau, pas un…
1  proxy très imparfait d'intensité d'intrants ch…
2  variable climatique complémentaire utile pour …
```

1.18 Visualisations des clés de jointure et des proxies

Ces graphiques traduisent visuellement les deux questions les plus importantes pour la suite : quelles tables sont propres sur leur clé potentielle, et dans quelle mesure les recouvrements entre fichiers sont suffisants pour construire une base enrichie sans perdre trop d'information.

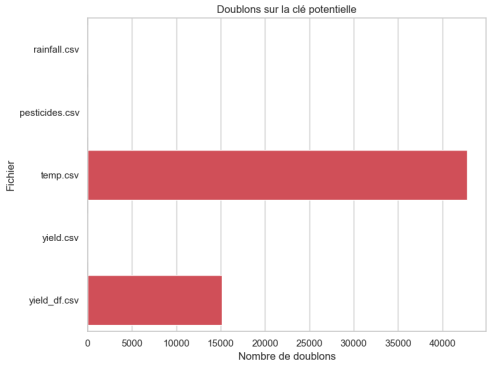

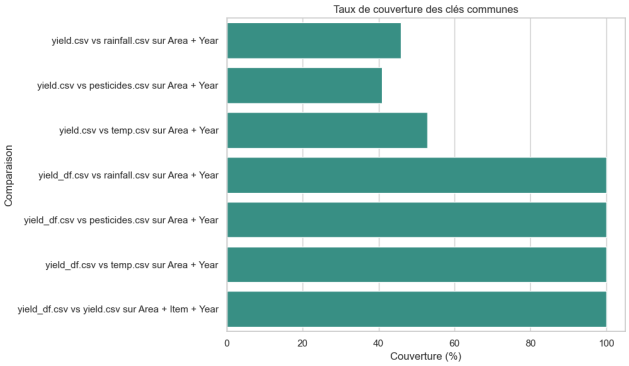

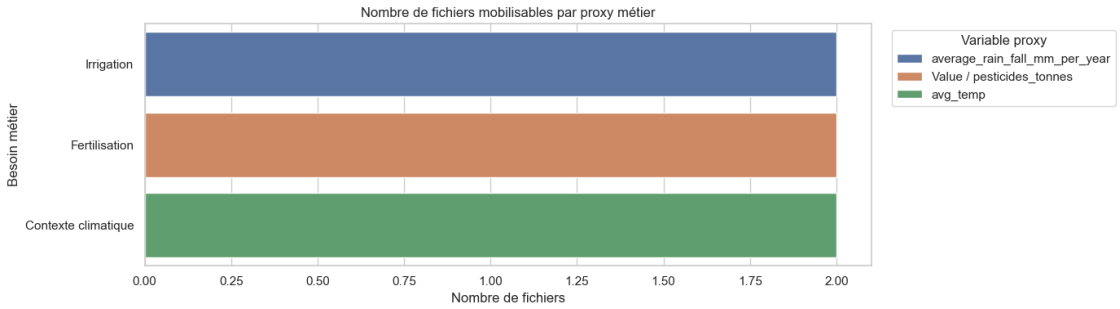

1.18.1 Choix de jointure, valeurs manquantes et variables proxy retenus

Les fichiers `rainfall.csv` et `pesticides.csv` sont les plus simples à raccorder à un futur dataset fusionné : leur granularité naturelle est `Area + Year`, sans doublon sur cette clé.

Le fichier `yield.csv` est le meilleur candidat pour servir de table de base, car il porte la cible de rendement avec une granularité plus fine, `Area + Item + Year`, sans doublon sur cette clé. La logique retenue pour la suite consiste donc à ajouter les variables climatiques et d'intrants à partir de `Area + Year`.

Le fichier `temp.csv` demande en revanche un vrai prétraitement avant jointure : il faut harmoniser `country` en `Area`, puis traiter les nombreux doublons `country + year` avant d'en faire une source de température fiable.

Les valeurs manquantes doivent être lues en deux temps. D'une part, certaines sources arrivent déjà incomplètes, notamment la pluie annuelle (`..` dans `rainfall.csv`) et la température moyenne dans `temp.csv`. D'autre part, une jointure gauche depuis `yield.csv` vers les tables d'enrichissement laisse des trous quand une clé `Area + Year` n'est pas couverte. Le choix retenu n'est donc pas de supprimer ces lignes en masse : la cible de rendement reste complète, et l'imputation est reportée au pipeline de modélisation pour éviter une perte d'observations injustifiée.

Le fichier `yield_df.csv` doit être lu comme un fichier déjà enrichi, utile pour audit ou contrôle, mais pas comme une source brute propre de départ. Le fait qu'il ne soit pas unique sur `Area + Item + Year` impose de le traiter avec prudence.

Enfin, sur les proxies métier, il faut rester précis :

- `average_rain_fall_mm_per_year` peut jouer le rôle de proxy indirect de disponibilité en eau, mais pas d'irrigation réelle ;
- `pesticides_tonnes` peut servir de proxy très imparfait de niveau d'intrants chimiques, mais pas de fertilisation à proprement parler ;
- `avg_temp` complète la lecture du contexte climatique, sans représenter un intrant agricole.

Ces choix sont expliqués ici dans le rapport ; leur mise en oeuvre opérationnelle est effectuée dans `preparation.ipynb`.

1.19 Choix de préparation du dataset `Agriculture CropYield`

Cette partie résume les choix de préparation retenus sur `crop_yield.csv`, qui correspond ici au dataset **Agriculture CropYield**. L'objectif est d'expliquer, dans le rapport, comment le jeu de données a été fiabilisé avant l'ACP et avant la modélisation.

Les opérations détaillées ne sont pas l'objet du rapport métier : on documente ici leur logique, leurs impacts et leurs limites. La préparation opérationnelle utilisée pour la suite du projet est portée par `preparation.ipynb`.

```
               indicateur       valeur
0               nb_lignes 1,000,000.00
1             nb_colonnes        13.00
2      valeurs_manquantes         0.00
3         doublons_lignes         0.00
4       doublons_colonnes         0.00
5     rendements_negatifs       231.00
6  outliers_iqr_rendement        84.00
7              memoire_mb       241.28
```

1.20 Choix de préparation retenus

Les décisions ci-dessous cherchent à rester sobres et défendables : on corrige ce qui gênerait l'analyse ou la suite du projet, sans transformer artificiellement le dataset.

- aucune imputation n'est nécessaire, car le fichier ne contient pas de valeur manquante ;
- aucune suppression de doublon n'est réalisée, car aucun doublon complet n'est détecté ;
- les noms de colonnes sont harmonisés en `snake_case` pour faciliter les manipulations et garder une convention homogène dans le projet ;
- les variables textuelles sont nettoyées par simple suppression d'espaces parasites, puis converties en `category` pour mieux refléter leur faible cardinalité ;
- les colonnes booléennes sont conservées comme booléens, car elles portent déjà une information métier propre et lisible ;
- les rendements négatifs sont retirés, car ils sont incohérents avec l'interprétation métier d'un rendement agricole ;
- les valeurs élevées mais positives ne sont pas supprimées ici : elles seront réévaluées plus tard dans la modélisation, afin d'éviter un nettoyage trop agressif.

```
                                          operation  \
0               Renommage des colonnes en snake_case
```

```
1  Suppression des espaces parasites sur les colo…
2     Conversion des colonnes textuelles en category
3       Conservation des colonnes booleennes en bool
4                Suppression des rendements negatifs

                                        impact  nb_lignes_impactees
0                     standardisation des noms                    0
1                   harmonisation des modalites                    0
2  meilleure lisibilite et optimisation memoire                    0
3     coherence metier des indicateurs oui/non                    0
4             retrait des valeurs incoherentes                  231

            etape  nb_lignes  nb_colonnes  valeurs_manquantes  \
0  avant_nettoyage    1000000           13                   0
1  apres_nettoyage     999769           13                   0

   doublons_lignes  rendements_negatifs  memoire_mb
0                0                   231      241.28
1                0                     0       39.09

                  colonne     dtype  nb_nan  nb_modalites
0                  region  category       0             4
1               soil_type  category       0             6
2                    crop  category       0             6
3             rainfall_mm   float64       0        999769
4     temperature_celsius   float64       0        999769
5         fertilizer_used      bool       0             2
6         irrigation_used      bool       0             2
7       weather_condition  category       0             3
8         days_to_harvest     int64       0            90
9   yield_tons_per_hectare   float64       0        999769
10          Rainfall_level  category       0             4
11       Temperature_level  category       0             4
12           Harvest_level  category       0             4

  region soil_type    crop  rainfall_mm  temperature_celsius  fertilizer_used  \
0   West     Sandy  Cotton       897.08                27.68            False
1  South      Clay    Rice       992.67                18.03             True
2  North      Loam  Barley       148.00                29.79            False

   irrigation_used weather_condition  days_to_harvest  yield_tons_per_hectare  \
0             True            Cloudy              122                    6.56
1             True             Rainy              140                    8.53
2            False             Sunny              106                    1.13

  Rainfall_level Temperature_level Harvest_level
0          Forte         Temperee+      Moyenne+
1          Forte           Fraiche        Longue
2         Faible         Temperee+      Moyenne+
```

1.20.1 Synthèse des choix de préparation

Le nettoyage reste volontairement léger : le dataset était déjà très propre sur les valeurs manquantes et les doublons. La seule correction réellement structurelle consiste à retirer les **231 rendements négatifs**, car ils ne sont pas compatibles avec une lecture métier du rendement agricole.

Le reste du travail relève surtout de l'harmonisation : colonnes renommées, catégories clarifiées, types stabilisés et structure rendue plus homogène pour les étapes suivantes.

1.21 ACP de cadrage analytique et identification des variables clés

L'analyse en composantes principales est utilisée ici comme **outil de cadrage analytique** sur le dataset `Agriculture CropYield`, conformément au brief. Son rôle n'est pas de nourrir directement le modèle, mais d'identifier les dimensions quantitatives explicatives les plus structurantes avant la fusion des données.

Les calculs détaillés, les graphiques ACP et la préparation technique associée sont exécutés dans `preparation.ipynb`, afin de garder `rapport.ipynb` purement explicatif. Le rendement n'est pas injecté comme variable active dans l'ACP : il sert seulement ensuite à interpréter les axes obtenus.

Les principaux apports de cette ACP sont les suivants :

- visualiser la structure conjointe de la pluie, de la température et de la durée du cycle cultural ;
- lire le rôle des axes factoriels sans fuite de la cible ;
- vérifier si une réduction de dimension forte est justifiée ;
- préparer une première hiérarchie des facteurs à confronter ensuite au dataset consolidé et au modèle final.

Sur ce dataset, l'ACP joue surtout un rôle **interprétatif** et non de compression massive. Les deux premiers axes n'expliquent qu'environ **66,8 %** de la variance des trois variables quantitatives explicatives, ce qui signifie qu'aucun axe unique ne résume à lui seul l'information utile. Avec un seuil de 90 %, il faut donc conserver **3 composantes**, soit l'ensemble des dimensions quantitatives étudiées.

L'enseignement métier est plus important que la réduction de dimension elle-même : la pluie est le facteur quantitatif le plus directement associé au rendement, la température apparaît comme une dimension distincte mais plus secondaire, et la durée du cycle cultural décrit une information complémentaire plutôt qu'un simple doublon de la pluie. Cette lecture est ensuite complétée par l'analyse des variables catégorielles et booléennes dans `preparation.ipynb`.

Les éléments ci-dessous sont générés dans `preparation.ipynb`, puis réutilisés ici pour documenter la démarche ACP dans le rapport. Cela permet de garder un rapport transparent pour un public métier, tout en laissant les calculs détaillés dans le notebook de travail.

Si les artefacts manquent, il faut soit réexécuter `preparation.ipynb`, soit lancer `python3 scripts/acp.py` pour régénérer rapidement les tableaux et figures ACP.

La lecture attendue est la suivante : le tableau de variance montre que l'ACP sert ici surtout à clarifier les rôles respectifs des variables quantitatives ; le cercle des corrélations montre les proximités ou oppositions entre pluie, température et durée du cycle ; la projection colore les observations selon le niveau de rendement sans faire entrer la cible dans le calcul des axes.

```
                    indicateur  valeur
0  dimension_intrinseque_90pct    3.00
1         variance_cumulee_pc2    0.67
2   variance_cumulee_conservee    1.00

  composante  variance_expliquee  variance_cumulee
0        PC1                0.33              0.33
1        PC2                0.33              0.67
2        PC3                0.33              1.00

              variable  contribution_absolue_pc1
0      days_to_harvest                      0.72
1          rainfall_mm                      0.69
2  temperature_celsius                      0.10
```

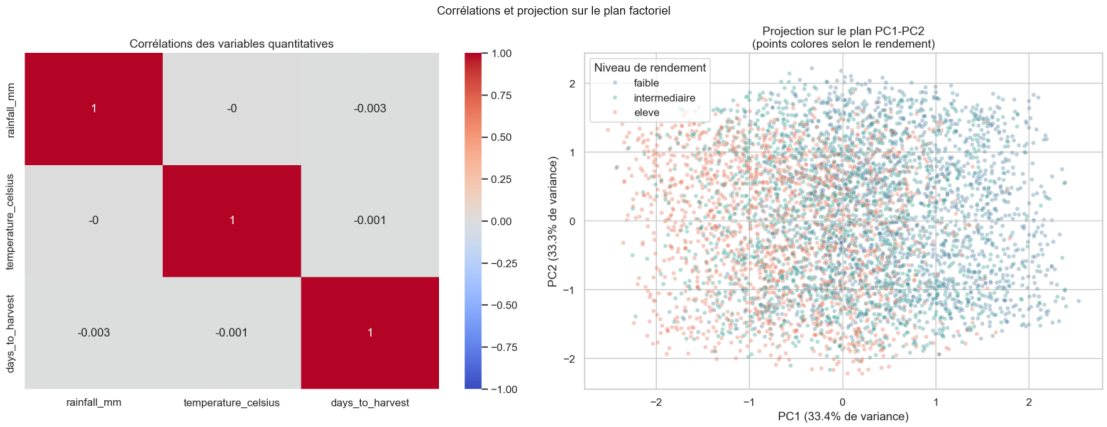
Corrélations et projection sur le plan factoriel
Corrélations des variables quantitatives
rainfall_mm
temperature_celsius
days_to_harvest
1
-0
-0.003
-0
1
-0.001
-0.003
-0.001
1
1.00
0.75
0.50
0.25
0.00
−0.25
−0.50
−0.75
−1.00
Projection sur le plan PC1-PC2
(points colores selon le rendement)
Niveau de rendement
faible
intermediaire
eleve
PC2 (33.3% de variance)
PC1 (33.4% de variance)

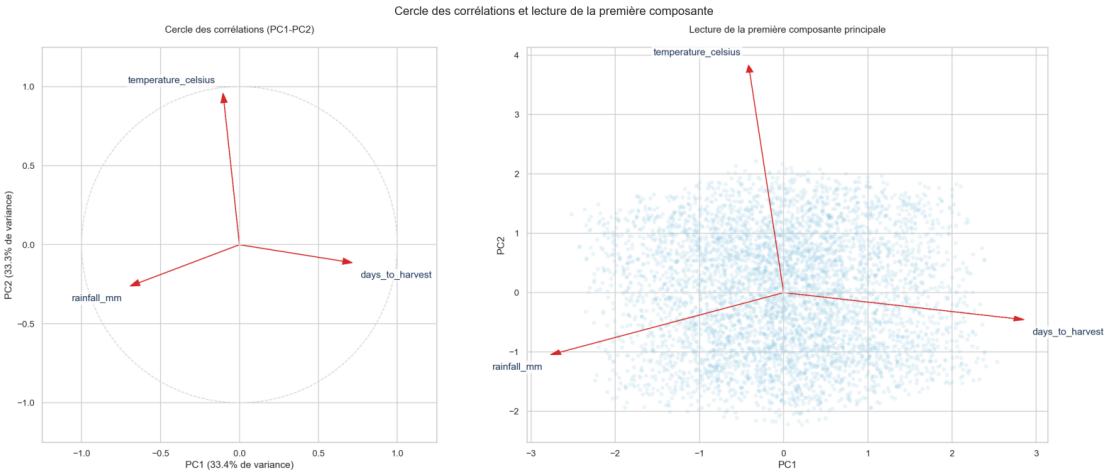
Cercle des corrélations et lecture de la première composante
Cercle des corrélations (PC1-PC2)
temperature_celsius
days_to_harvest
rainfall_mm
PC2 (33.3% de variance)
PC1 (33.4% de variance)
Lecture de la première composante principale
temperature_celsius
days_to_harvest
rainfall_mm
PC2
PC1

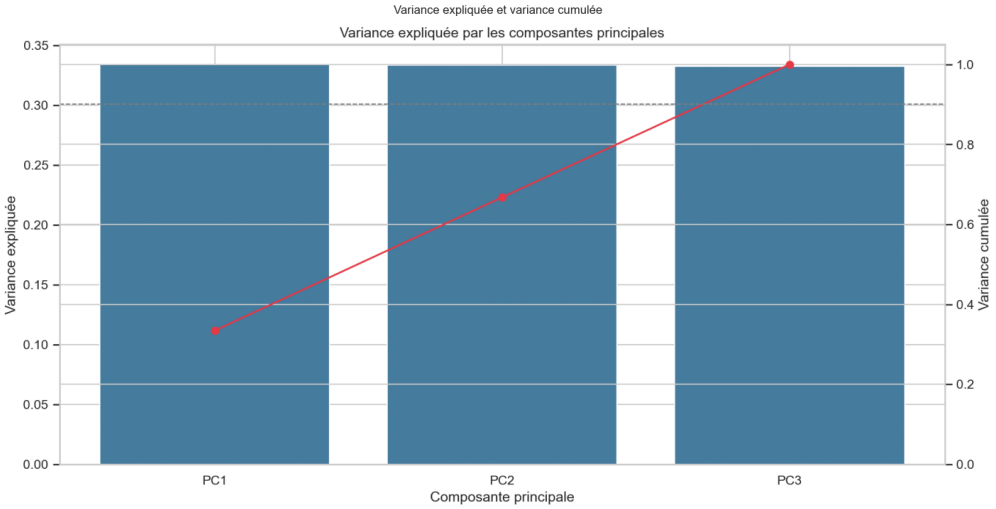
Variance expliquée et variance cumulée
Variance expliquée par les composantes principales
Variance expliquée
Variance cumulée
PC1
PC2
PC3
Composante principale

1.22 Validation croisée des facteurs identifiés

La logique attendue par la mission est la suivante : identifier d'abord des facteurs clés sur `Agriculture CropYield`, puis vérifier qu'ils restent cohérents lorsqu'on passe au dataset consolidé utilisé pour la modélisation.

Ce que l'analyse amont suggère : la pluie domine la lecture quantitative, tandis que l'irrigation et la fertilisation créent des écarts de rendement beaucoup plus visibles que les différences entre cultures ou entre régions.

Ce que le dataset consolidé confirme : la fusion conserve bien les facteurs annuels liés à l'eau, au climat et à l'intensité des intrants (`average_rain_fall_mm_per_year`, `avg_temp`, `pesticides_tonnes` comme proxy), l'audit sur `yield_df.csv` valide le scénario de jointure sur les clés communes, et les valeurs manquantes restantes sont assumées comme un sujet de prépro-cessing de l'étape 2 plutôt qu'un motif de suppression massive des observations.

Ce que la modélisation retrouve : le meilleur pipeline s'appuie sur les variables brutes consolidées, et non sur une ACP injectée dans le modèle. C'est cohérent avec les résultats observés sur les baselines linéaires : la réduction de dimension n'apporte pas de gain mesurable sur ce problème.

```
               model  test_mae  test_rmse  test_r2  \
0      random_forest      1.11       1.98     0.92
1  gradient_boosting      2.25       3.42     0.75
2  linear_regression      2.66       3.93     0.67
3              ridge      2.66       3.93     0.67
4  ridge_numeric_pca      2.66       3.93     0.67
5              dummy      4.91       6.82    -0.00

                                        best_params
0  {"regressor__n_estimators": 250, "regressor__m…
1  {"regressor__n_estimators": 250, "regressor__m…
2                                                {}
3                         {"regressor__alpha": 0.1}
4  {"preprocessor__num__pca__n_components": 4, "r…
5                                                {}
```